

# IR-MCL: Implicit Representation-Based Online Global Localization

## Abstract

本文解决了使用 **2D 激光雷达数据** 在室内环境中估计机器人姿态的问题，并研究了基于已有环境模型的**蒙特卡洛定位（MCL）**系统。我们提出了用神经占用场来隐式表示机器人定位任务中的二维地图。通过预训练的网络，我们可以渲染合成当前场景下任意机器人姿态所对应的**2D 激光扫描**。基于隐式表示，我们可以获得合成扫描与实际扫描之间的相似度并将其作为观测模型，然后将其集成到 MCL 系统中进行准确的定位。我们在自行录制的数据集和三个公开可用的数据集上评估了方法。实验表明，我们可以准确高效地定位机器人，超越了最先进方法的定位性能。实验证明，所呈现的隐式表示能够预测更准确的 **2D 激光雷达扫描**，从而为基于粒子滤波的定位提供了改进的观测模型。

## Introduction

本文的主要贡献是利用基于隐式 **NeRF** 的环境表示与 **MCL** 结合，以及利用这种隐式表示的观测模型。它解决了离散占用栅格地图的局限性，并提高了定位的准确性。我们提出的方法使用**神经占用场（neural occupancy field）**，命名为 **NOF**，通过**隐式函数对 2D 世界**进行表示。它利用**多层感知器（MLP）**来对 2D 世界进行编码。给定一个位置，MLP 输出相应的占用概率。基于此，本文方法使用**基于射线投射的渲染算法**来为输入传感器位姿合成一个范围扫描，详见图 1 的示意图。我们通过**比较渲染的合成扫描与实际传感器测量值**来训练 **NOF**。我们使用 **NOF** 构建了一种新的 MCL 观测模型。对于 MCL 中的每个粒子，我们使用 **NOF** 来渲染一个合成视图，并将其与当前观测进行比较以更新粒子权重。

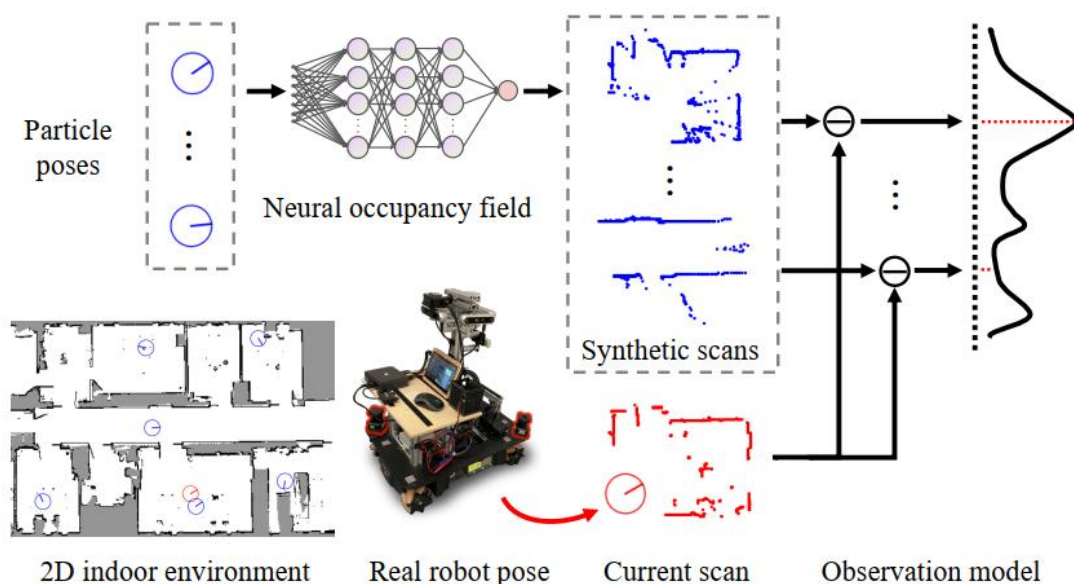


图 1. 针对一组粒子和来自 2D LiDAR 的实际扫描，我们利用预训练的神经表示建立一个观测模型，以实现精准的机器人全局定位。

总的来说，我们提出以下三个关键观点：

- (i) 我们能够基于所提出的**隐式环境表示**构建有效的观测模型，用于基于 2D LiDAR 的（全局）定位；
- (ii) 与使用占用栅格地图的方法相比，我们实现了最先进的定位性能；
- (iii) 能够快速收敛以实现对机器人的**全局定位**，并能在线运行。我们通过多个数据集上的实验评估来支持这些观点。

## Approach

为了实现 IR-MCL，我们研究了通过神经隐式表示在场景中生成任意传感器位置的 2D LiDAR 扫描，以实现机器人的全局定位。为此，我们提出了一个神经网络，用于**预测给定位置的占据概率**，以详细表示 2D 环境，如第 III-A 节所述。基于沿 LiDAR 射线的样本的预估占据概率，我们为机器人的给定位姿渲染一个合成的 LiDAR 扫描，如第 III-B 节所示。与训练过程中来自 2D LiDAR 的实际测量相比，我们**优化网络的权重**，如第 III-C 节所述。之后，我们使用训练好的网络构建一个新颖的**观测模型**，并将其整合到 MCL 框架中，以实现高效的全局定位，如第 III-D 节所示。图 2 显示了我们方法的概述。




图 2. 方法概述：神经占据场（NOF）生成合成 LiDAR 测量的过程。我们沿着每个 LiDAR 射线均匀采样多个位置。NOF 是一个神经网络，以 2D 位置  $\mathbf{p} = (x, y)$  作为输入，并输出其占据概率。我们可以通过体素渲染沿着 LiDAR 射线的所有预测来合成距离值。

### A. 隐式表示：神经占据场

我们提出了一种神经网络，用于预测输入二维位置的占据概率，作为隐式场景表示，简称神经占据场或 NOF。方法使用函数  $F_{\Theta}$  来隐式表示连续的二维世界。以二维位置  $\mathbf{p} = (x; y)$  作为输入，并输出相应的占据概率  $p_{occ}$ ，如下所示：

$$p^{occ} = F_{\Theta}(\gamma(\mathbf{p})). \quad (1)$$

我们使用受 NeRF [19] 启发的 MLP 来表示  $F_{\Theta}$ ，其中  $\Theta$  表示神经网络的权重。与 NeRF 一致，我们还使用位置编码将二维位置投影到高维空间，以鼓励模型编码世界的高频信息。我们使用位置编码  $\gamma(\mathbf{p})$  如下：

$$\gamma(\mathbf{p}) = [\mathbf{p}, \sin(2^0 \mathbf{p}), \cos(2^0 \mathbf{p}), \dots, \sin(2^{L-1} \mathbf{p}), \cos(2^{L-1} \mathbf{p})], \quad (2)$$

网络经过训练，可以将任意输入的二维坐标映射到相应的占据概率。为了实现这一点，多层感知器（MLP）由 8 个全连接层组成，每个层后面都跟有批归一化 [13] 和 ReLU 激活函数。另外，我们采用并包含了残差连接 [11] 来提高预测的准确性。我们在由 MLP 生成的 D 维特征向量上应用一个额外的全连接层，其后跟一个 sigmoid 激活函数，以获得占据概率  $p_{occ} \in [0, 1]$ 。

网络预测占据概率  $p_{occ} \in [0, 1]$ ，可用于表示二维场景。这与现有的神经表示方法不同，例如 NeRF [19]，后者表示从预测的体积密度中得到的场景几何信息。我们提出的网络无需进行阈值调整即可获取占据状态（空闲或占用）。因此，它能很好地适用于不同的场景。

### B. 利用 NOF 进行新视角渲染

基于我们提出的 NOF 表示，我们可以通过射线投射算法为环境中的任意二维姿态渲染新的 LiDAR 扫描。

具体来说，给定机器人的当前二维姿态  $\mathbf{x} = (x; y; \theta)^T$ ，我们确定 LiDAR 的每个射线的起点  $\mathbf{o} = (x; y)^T$  和归一化方向向量  $\mathbf{d} = (d1; d2)^T$ 。射线的方向向量  $\mathbf{d}$  是根据机器人方向  $\theta$  和二维 LiDAR 传感器的参数计算的。我们均匀采样  $N$  个点  $\mathbf{p}_i = \mathbf{o} + m_i \mathbf{d}$  沿着射线，其中  $m_i$  是从起

点  $o$  到采样点  $p_i$  的距离,受到二维 LiDAR 传感器有效测量范围的限制,即  $m_i \in [m_{\min}; m_{\max}]$ 。类似于先前的工作 [29],我们将沿着射线的终点  $p_i$  处的终止权重  $\alpha_i$  建模为:

$$\alpha_i = p_i^{\text{occ}} \prod_{j=1}^{i-1} (1 - p_j^{\text{occ}}), \quad (3)$$

我们假设所有的占据概率  $p_i^{\text{occ}}$  都是独立的。有了这个模型,我们可以通过样本点  $p_i$  处的终止权重和沿着射线的距离  $m_i$  来计算出一个范围:

$$r = \sum_{i=1}^N \alpha_i m_i. \quad (4)$$

对于每个 LiDAR 射线重复这个过程,我们可以在**基于 NOF 的任意查询位置  $x$  处渲染出一个合成的观测,并将此扫描与实际扫描进行比较,用于 MCL 观测模型。**

### C. 训练 NOF

基于上述介绍的渲染算法,我们可以像构建传统 MCL 的地图时那样使用记录的二维 LiDAR 扫描和相应的姿态来训练神经网络  $F_{\Theta}$ 。每个时刻  $t$  的扫描  $z_t$  是从一个姿态  $x_t$  记录的。根据 LiDAR 传感器的参数,每个扫描由  $B$  束组成,每个光线对应于第  $i$  束的实际距离值  $\hat{r}_i \in \mathbb{R}$ 。我们使用两种损失函数来优化 MLP 网络的权重  $\Theta$ ,一种是几何损失,另一种是占据率正则化。

1) 几何损失:我们使用  $L_1$  损失计算渲染的距离值  $r_i$  和第  $i$  束的记录距离值  $\hat{r}_i$  之间的几何损失:

$$\mathcal{L}_{geo} = \frac{1}{B} \sum_{i=1}^B |r_i - \hat{r}_i|. \quad (5)$$

我们选择使用  $L_1$  损失而不是  $L_2$  损失,以减少所使用的二维 LiDAR 传感器的测量噪音的影响。(L1 对异常值、离群点更鲁棒)

L1 损失函数也叫平均绝对值误差 (MAE),不妨设标签为  $Y = (y_1, y_2, \dots, y_m)_{1 \times m}$ , 样本  $X_{ij(n \times m)}$ , 经过一个黑箱有对标签的估计函数:  $f(X) = \hat{Y}$ 。这个时候, L1损失函数记为这个估计和真实标签的平均误差,也就是:

$$\text{Loss1} = \frac{1}{m} \sum_{i=1}^m |y_i - f(x_i)|$$

沿用上面对标签和样本的符号定义, L2损失函数也叫平均平方损失函数 (MSE), 它的数学形式如下:

$$\text{Loss2} = \frac{1}{m} \sum_{i=1}^m (y_i - f(x_i))^2$$

2) 占用规则化: NOF 中的预测值被视为输入位置的占用值。因此,期望  $p_{\text{occ}}$  等于 1 表示占用空间,等于 0 表示自由空间。这意味着理想情况下,预测的占用概率的熵应该为 0。类似地,我们添加负对数似然损失作为规范化,以减少预测的占用概率的熵:

$$\mathcal{L}_{reg} = \frac{1}{NB} \sum_{i=1}^{NB} \log(F_{\Theta}(p_i)) + \log(1 - F_{\Theta}(p_i)), \quad (6)$$

$N$  是每条光线上采样点数量,最终损失函数为:

$$\mathcal{L} = \mathcal{L}_{geo} + \lambda \mathcal{L}_{reg}, \quad (7)$$

其中,  $\lambda$  是一个超参数, 用于平衡占用规范化的影响。

我们使用 Adam 优化器 [15] 训练 NOF 网络, 批量大小为 1024。在所有实验中, 我们沿每个光束采样 256 个点, 即 ( $N = 256$ ), 并将网络训练 32 个周期。初始学习率为  $10^{-4}$ , 在第 4 个周期和第 8 个周期时减小为原来的 0.5, 权重衰减为 (0.001)。

D. 隐式表示 MCL (IR-MCL) 基于 NOF 网络渲染的观察结果, 我们为 MCL 提出了一种新的观察模型, 以实现全局定位。全局定位被制定为后验概率估计问题[34], 其目标是估计在时刻  $t$  处的机器人位姿  $\mathbf{x}_t = (\mathbf{x}; \mathbf{y}; \theta)$ 。信念  $\text{bel}(\mathbf{x}_t)$  的更新使用递归贝叶斯滤波器, 并且被制定为:

$$\text{bel}(\mathbf{x}_t) = \eta p(\mathbf{z}_t | \mathbf{x}_t, \mathcal{M}) \overline{\text{bel}}(\mathbf{x}_t), \quad (8)$$

其中,  $\text{bel}(\mathbf{x}_t)$  是机器人位姿  $\mathbf{x}_t$  在运动控制和上一个位姿  $\mathbf{x}_{t-1}$  的情况下的预测置信度, 也被称为机器人的运动模型。 $p(\mathbf{z}_t | \mathbf{x}_t; \mathcal{M})$  是传感器测量  $\mathbf{z}_t$  在机器人状态  $\mathbf{x}_t$  下在地图  $\mathcal{M}$  中的似然度, 也被视为校正运动模型估计的观察模型。 $\eta$  是归一化因子。

MCL 利用粒子滤波器来逼近后验  $\text{bel}(\mathbf{x}_t)$  的更新, 通过从后验中绘制一组随机样本来实现。这些随机样本被称为粒子, 表示为  $\mathbf{X}_t = \{ (\mathbf{x}_{1t}, w_{1t}), (\mathbf{x}_{2t}, w_{2t}), \dots, (\mathbf{x}_{Mt}, w_{Mt}) \}$ , 其中  $w_i$  是位姿  $\mathbf{x}_i$  的权重,  $M$  是粒子数量。在更新后, 根据粒子的重要性权重对粒子进行重新采样。重复此过程, 粒子最终会收敛到实际位姿周围的一个小区域。

在这项工作中, 利用 NOF 模型隐式表示环境  $\mathcal{M}$ , 以生成用于 MCL 中的观察模型的扫描, 从而实现全局定位。具体来说, IR-MCL 将每个粒子视为时刻  $t$  的假设机器人位姿, 即  $\mathbf{x}_t^i = (x^i, y^i, \theta^i)_t^\top$ 。我们在每个粒子位置上渲染一个观测  $\mathbf{z}_t^i$ , 如第 III-B 节所述, 并将其与由 2D LiDAR 传感器获得的实际测量  $\hat{\mathbf{z}}_t$  进行比较, 如图 3 所示。

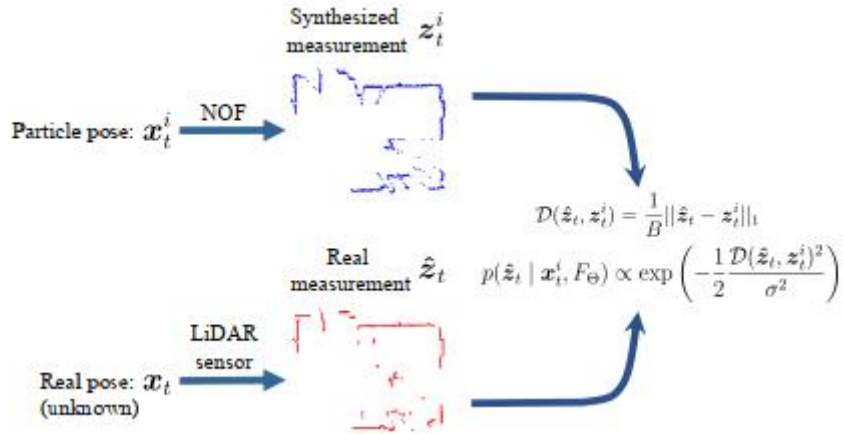


图 3. 隐式表示的观察模型。我们为每个粒子渲染一个 2D 激光雷达扫描, 然后通过将合成的测量与激光雷达传感器的实际测量进行比较来更新粒子的权重。

按照[4]的做法, 我们通过高斯分布来近似第  $i$  个粒子的似然度。

$$p(\hat{\mathbf{z}}_t | \mathbf{x}_t^i, F_\Theta) \propto \exp\left(-\frac{1}{2} \frac{D(\hat{\mathbf{z}}_t, \mathbf{z}_t^i)^2}{\sigma^2}\right), \quad (9)$$

其中,  $D$  是测量合成观测值和真实观测值之间的差异。我们使用 L1 距离来计算  $D$ 。它对测量的噪声具有鲁棒性, 易于使用, 并保持高效率。通过将当前真实传感器测量与在所有粒子位置渲染的合成观察进行比较, 我们更新似然度  $p(\hat{\mathbf{z}}_t | \mathbf{x}_t, F_\Theta)$ 。

为了加速在使用大量粒子时 IR-MCL 的运行时间，例如  $M=100,000$ ，我们构建了一个预定义的 2D 网格来存储预测概率，以加速类似[12]的渲染，并将其称为神经占用网格(NOG)。NOG 将覆盖当前场景的整个空间。在定位期间，我们使用 NOG 中沿射线的每个采样点的最近邻单元格作为该点的占用概率。通过利用 NOG，IR-MCL 系统即使在具有大量粒子的情况下也能实现实时性能。

### **Conclusion**

在本文中，我们提出了一种基于隐式表示的在线定位方法，使用 2D 激光雷达。方法利用基于神经网络的场景表示来构建准确的观察模型。这使得我们能够成功地在给定环境中定位移动平台，并在定位精度方面优于现有的基准 MCL。